

Применение методов доменной адаптации для задач обработки изображений

Выполнила:

Анна Володкевич, студентка образовательной программы «Науки о данных»

Консультант:

Сергей Овчаренко, Senior Research Engineer, Яндекс

Доменная адаптация: постановка задачи

Исходный домен

$$S = \{(\mathbf{x}_i, y_i)\}_{i=1}^n \sim (\mathcal{D}_S)^n$$



Целевой домен

$$T = \{\mathbf{x}_i\}_{i=n+1}^N \sim (\mathcal{D}_T^X)^{n'}$$

$$\eta: X \rightarrow Y$$



Задачи работы

- Обзор методов доменной адаптации для задачи классификации изображений
- Воспроизведение выбранной архитектуры и ее модификация для улучшения результатов по сравнению с результатами статьи

Критерии успеха

- Удалось воспроизвести выбранную архитектуру
- В ходе работы удалось добиться статистически значимого повышения качества моделей в метрике accuracy

Содержание

1

Постановка задачи и ее актуальность

2

Теоретическая часть:

- Distance-based методы
- Adversarial-based методы
- Pseudo-labeling

3

Практическая часть:


- Проведенные эксперименты
- Результаты экспериментов

4

Результаты

Подходы и проблемы


Цель: обучить нейронную сеть предсказывать классы для целевого и исходного домена



Проблемы:

- нет меток y^t для обучения
- распределения признаков для исходного и целевого доменов отличаются (доменный сдвиг)

Подходы и проблемы




No Adaptation

$$P(x) \neq Q(x)$$

Проблемы

Доменный сдвиг распределений

Не можем напрямую приближать совместные распределения признаков и меток




Match Marginal Distributions

$$P(x) \approx Q(x)$$

Идеи и решения

Приближать распределения признаков целевого и исходного доменов с использованием статистических критериев (**distance-based**) и состязательных сетей (**adversarial-based**)

- Косвенно приближать совместные распределения
- Размечать данные целевого домена с использованием дополнительных методов (**pseudo-labeling**).



Match Joint Distributions

$$P(x,y) \approx Q(x,y)$$

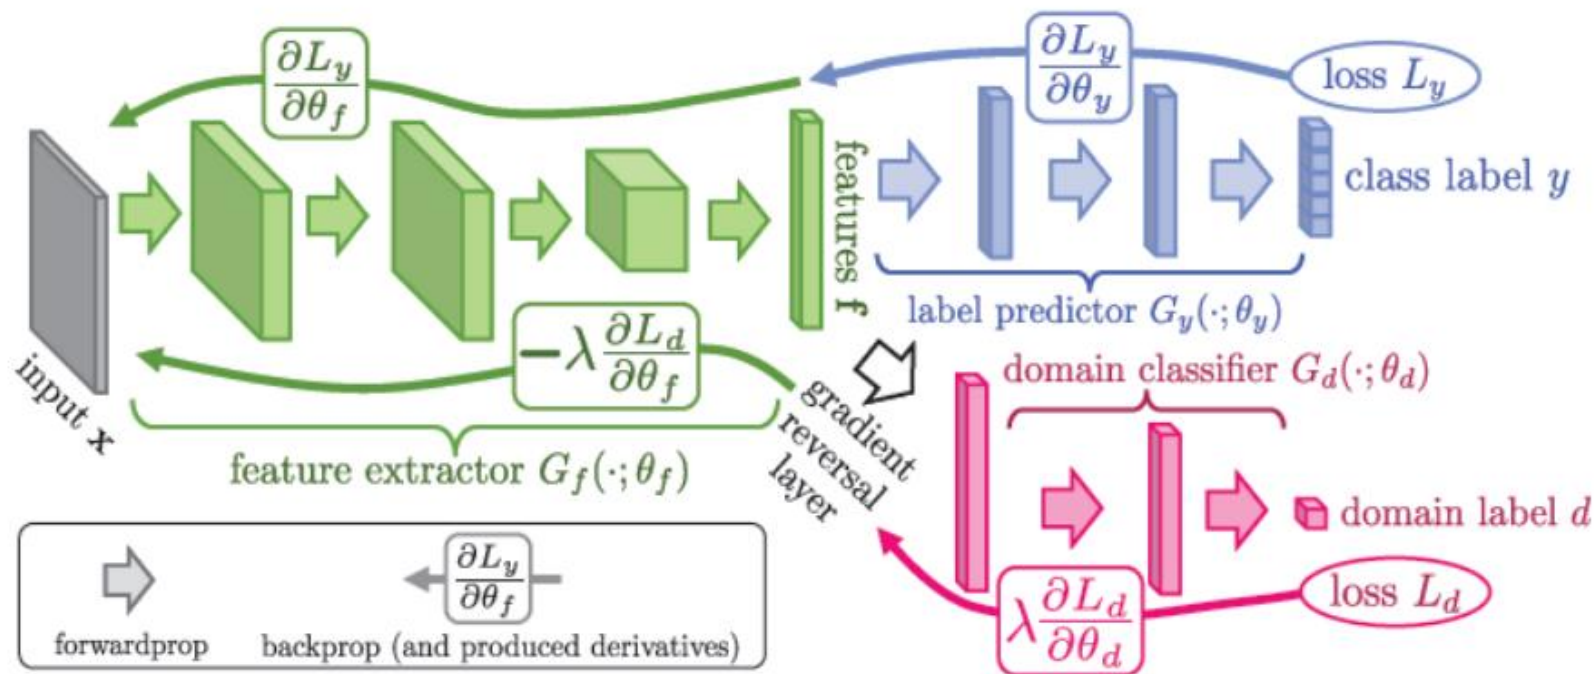
Сравнение подходов

Модель	Год	Метод	acc Office31 A->W	acc Office31 W->A	mean acc Office31
CAN	2019	Distance-based + Pseudo-Labeling	0.945	0.77	0.906
SDA-TCL	2019	Adversarial + Pseudo-Labeling	0.924	0.776	0.902
SPL	2019	Distance-based + Pseudo-Labeling	0.927	0.763	0.896
<i>DADA</i>	<i>2019</i>	<i>Adversarial</i>	0.923	0.742	<i>0.89</i>
ALDA	2020	Adversarial	0.956	0.725	0.887
DANN-CA	2018	Adversarial	0.9135	0.6876	0.862
JAN ResNet 50	2017	Distance-based	0.86	0.707	0.846
ADDA	2017	Adversarial	0.862	0.689	0.829
DANN ResNet 50	2016	Adversarial	0.826	0.661	0.828
JAN AlexNet	2017	Distance-based	0.752	0.563	0.763
D-CORAL	2016	Distance-based	0.664	0.515	0.721
DANN AlexNet	2016	Adversarial	0.73	-	0.743
DAN AlexNet	2015	Distance-based	0.68	0.53	0.72

Adversarial-based методы: DANN

Проблема: есть доменный сдвиг

Решение: приблизим домены с использованием дискриминатора



Модель DANN, использующая классификационную и доменные функции потерь и *gradient reversal layer* для сближения распределений признаков данных двух доменов

Содержание

1

Постановка задачи и ее актуальность

2

Теоретическая часть:

- Distance-based методы
- Adversarial-based методы
- Pseudo-labeling

3

Практическая часть:

- Проведенные эксперименты
- Результаты экспериментов

4

Результаты

Dataset

Office-31: 31 класс предметов повседневных объектов из трех доменов




Домен	Amazon	DSLR	Webcam
Количество изображений	2817	498	795

A -> W

Базовая модель

ResNet50

ОДИН
ПОЛНОСВЯЗНЫЙ
СЛОЙ





Эксперименты

Кратко: воспроизвести DANN, попробовать различные модификации архитектур
Попробовать использовать эмбединги, полученные из обученных моделей в качестве входных данных для SPL

- 1) One Domain Model: Обучение baseline: классификатора на основе ResNet50
- 2) DANN: Воспроизведение архитектуры и обучение модели DANN с базовой моделью ResNet50
- 3) Rich DANN: Эксперимент с усилением классификатора DANN
- 4) Rich DANN with bottleneck: Эксперимент с добавлением bottleneck (сужения векторного представления изображений перед разделением классификаторов).
- 5) Rich DANN Entropy: Эксперимент с добавлением энтропийной регуляризации при предсказании классов target domain
- 6) DANN-CA: Воспроизведение архитектуры и обучение модели DANN с базовой моделью ResNet50
- 7) DANN to SPL: Эксперименты с использованием эмбедингов, полученных из DANN, в качестве входных данных для архитектуры SPL.

Rich DANN

Основная идея: более сложный, чем в ResNet50, классификатор классов с dropout



Модель	Accuracy A->W
DANN (опубликованный результат)	0.826
ResNet50 72	0.73 ± 0.015
Rich DANN ResNet50	0.747 ± 0.006
Rich DANN ResNet50 141	0.843 ± 0.017
Rich DANN ResNet50 129	0.865 ± 0.017
Rich DANN ResNet50 72	0.83 ± 0.027


Rich DANN entropy

Основная идея: минимизация энтропии классификатора на целевом домене

Энтропийная
регуляризация на
целевом домене (DADA)

$$\mathcal{L}_{em}^t(G, F) = \frac{1}{n_t} \sum_{j=1}^{n_t} \mathcal{H}(\bar{\mathbf{p}}(\mathbf{x}_j^t)),$$

$$\mathcal{H}(x) = - \sum_{i=1}^k p(x_i) \log(p(x_i))$$



Модель	Accuracy A->W
Rich DANN ResNet50 129	0.865 ± 0.017
Rich DANN ResNet50 129 entropy 1	0.897 ± 0.005
Rich DANN ResNet50 129 entropy 0.5	0.877 ± 0.012

Выводы по экспериментам

- Задачи доменной адаптации требуют большого внимания к настройке гиперпараметров. Так, например, слишком быстрый рост веса доменной функции потерь приводит к стабильному ухудшению качества в процессе обучения, которое невозможно отследить без знания меток целевого домена.
- Подбор гиперпараметров и оптимальной архитектуры для реальной задачи очень осложняется из-за отсутствия разметки target domain и немонотонно изменяющихся loss-функций.
- Результаты статей довольно сложно повторить. Возможно, из-за разницы в используемых фреймворках и предобученных моделях, а также недостаточного описания гиперпараметров моделей и процесса обучения.

Содержание

1

Постановка задачи и ее актуальность

2

Теоретическая часть:

- Distance-based методы
- Adversarial-based методы
- Pseudo-labeling

3

Практическая часть:

- Проведенные эксперименты
- Результаты экспериментов

4

Результаты

Результаты

Модель	Accuracy	Accuracy	Accuracy
	A->W	W->A	VisDA
ResNet50 (baseline)	0.73 \pm 0.015	0.635 \pm 0.009	0.407
DANN ResNet50 (опубликованные результаты), 2016	0.826	0.661	0.574
DANN ResNet50 Rich	0.864 \pm 0.016	0.699 \pm 0.006	0.668 \pm 0.015
DANN ResNet50 Rich Entropy	0.897 \pm 0.005	0.697 \pm 0.005	0.668 \pm 0.016

- ✓ Удалось добиться улучшения качества по сравнению с опубликованными результатами за счет усложнения классификатора и использования энтропийной регуляризации (примерно до результатов статей 2018 года)
- ✓ Практические результаты (исходный код) могут быть использованы для решения задач классификации изображений для любой пары доменов.
- ✓ Рассмотренные модификации архитектуры могут быть применены для любой уже существующей архитектуры Domain Adaptation
- ✓ Результаты могут рассматриваться в качестве ablation study для более современных архитектур (DADA)

Актуальность задачи


Почему разметка целевого домена вручную не всегда решение?

- Качественный, большой и размеченный датасет уже есть
- Умеем хорошо моделировать данные
- Реальные данные встречаются редко и сложно собрать их в принципе
- Ручная разметка данных дорогая и может содержать ошибки

Distance-based методы

Проблема: есть доменный сдвиг

Решение: приблизим домены с использованием статистических критериев



Критерий Maximum Mean Discrepancy

$$\widehat{D}_{\mathcal{H}}(P, Q) = \|\widehat{\mu}_{\mathbf{Z}^s, l}(P) - \widehat{\mu}_{\mathbf{Z}^t, l}(Q)\|_{\mathcal{H}}^2$$

Inner product in \mathcal{H} :

$$\langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle_{\mathcal{H}} = k(\mathbf{x}, \mathbf{x}')$$

$$\widehat{\mu}_{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \phi(\mathbf{x}_i)$$

Архитектура DAN, минимизирующая MMD для выходов полносвязных слоев на данных целевого и исходного доменов


Long, Mingsheng, Yue Cao, Jianmin Wang, u Michael I. Jordan. «Learning Transferable Features with Deep Adaptation Networks.»

arxiv. 2015. <https://arxiv.org/abs/1502.02791>.

Distance-based методы

Проблема: приближаем распределения без обусловленности на класс

Решение: пытаемся приблизить совместное распределение



Joint Maximum Mean Discrepancy

$$D_{\mathcal{L}}(P, Q) \triangleq \|\mathcal{C}_{\mathbf{Z}^{S,1:|L|}}(P) - \mathcal{C}_{\mathbf{Z}^{T,1:|L|}}(Q)\|_{\otimes_{\ell=1}^{|L|} \mathcal{H}^{\ell}}^2.$$

$$\begin{aligned} \widehat{D}_{\mathcal{L}}(P, Q) = & \frac{1}{n_s^2} \sum_{i=1}^{n_s} \sum_{j=1}^{n_s} \prod_{\ell \in \mathcal{L}} k^{\ell}(\mathbf{z}_i^{s\ell}, \mathbf{z}_j^{s\ell}) \\ & + \frac{1}{n_t^2} \sum_{i=1}^{n_t} \sum_{j=1}^{n_t} \prod_{\ell \in \mathcal{L}} k^{\ell}(\mathbf{z}_i^{t\ell}, \mathbf{z}_j^{t\ell}) \\ & - \frac{2}{n_s n_t} \sum_{i=1}^{n_s} \sum_{j=1}^{n_t} \prod_{\ell \in \mathcal{L}} k^{\ell}(\mathbf{z}_i^{s\ell}, \mathbf{z}_j^{t\ell}). \end{aligned}$$

Архитектура JAN, минимизирующая меру несоответствия совместных распределений признаков целевого и исходного доменов


Long, Mingsheng, Han Zhu, Jianmin Wang, u Michael I. Jordan. «Deep Transfer Learning with Joint Adaptation Networks.» arxiv.

2016. <https://arxiv.org/abs/1605.0663>.

Adversarial-based методы

Проблема: приближаем распределения без обусловленности на класс

Решение: пытаемся приблизить совместное распределение



Энтропийная
регуляризация на
целевом домене

$$\mathcal{L}_{em}^t(G, F) = \frac{1}{n_t} \sum_{j=1}^{n_t} \mathcal{H}(\bar{\mathbf{p}}(\mathbf{x}_j^t)),$$

Архитектуры DANN-CA, DADA, использующие классификацию на $n+1$ класс (индикатор целевого домена)

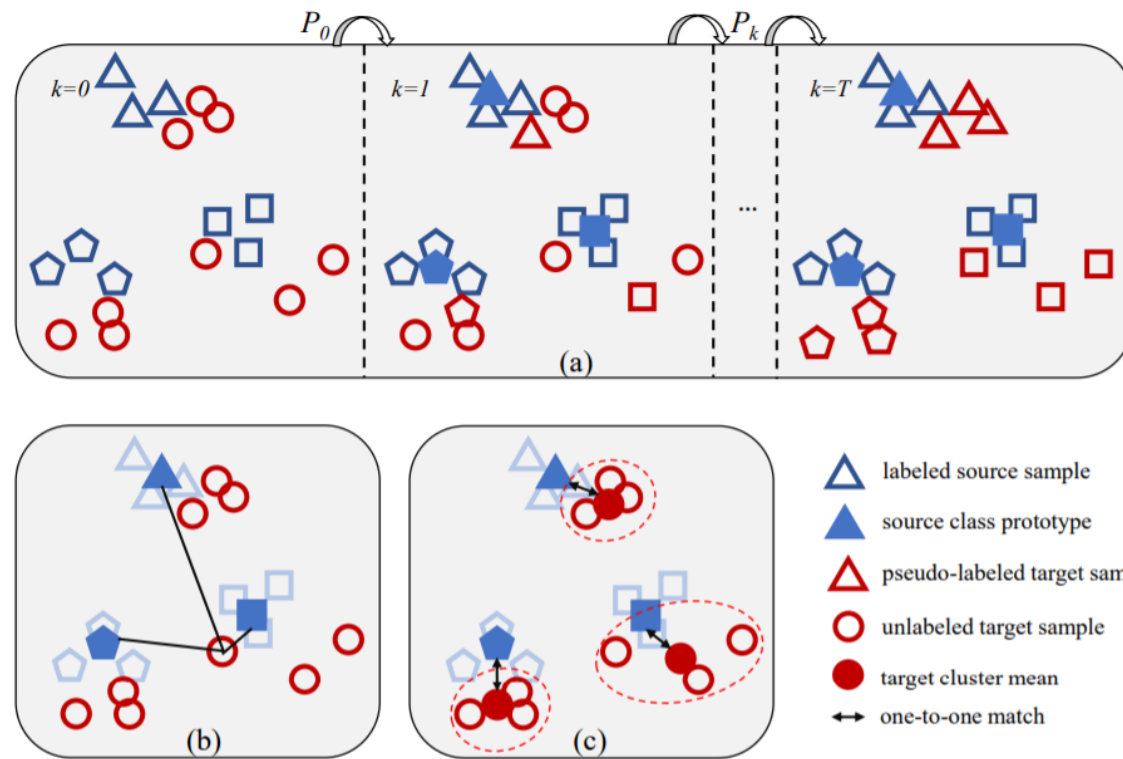
Tang, Hui, u Kui Jia. «Discriminative Adversarial Domain Adaptation.» arxiv. 2019. <https://arxiv.org/pdf/1911.12036>.

Tran, Luan, Kihyuk Sohn, Xiang Yu, Xiaoming Liu, u Manmohan Chandraker. «Gotta Adapt 'Em All: Joint Pixel and Feature-Level Domain Adaptation for Recognition in the Wild.» arxiv. 2018. <https://arxiv.org/abs/1803.00068>.

Pseudo-labeling

Задача: Лучше приблизить совместные распределения

Решение: кластеризовать данные и попробовать назначить pseudo-labels



- 1) Извлечем признаки изображений
- 2) Применим метод главных компонент (PCA)
- 3) По размеченным данным построим проекционную матрицу P , переводящую признаковые описания в латентное пространство с использованием Supervised Locality Preserving Projection (SLPP)
- 4) Применим P к признаковым описаниям объектов, кластеризуем данные с помощью k-means и присвоим pseudo-labels



Повторять до сходимости (10-20 итераций)

Архитектура SPL

Wang, Qian, u Toby P. Breckon. «Unsupervised Domain Adaptation via Structured Prediction Based Selective Pseudo-Labeling.» arxiv. 2019. <https://arxiv.org/abs/1911.07982>.

Rich DANN bottleneck


Основная идея: сужение векторного представления перед разделением классификаторов



Модель	Accuracy A->W
Rich DANN ResNet50 141	0.843 ± 0.017
Rich DANN ResNet50 141 bottleneck 256	0.863 ± 0.016
Rich DANN ResNet50 129	0.865 ± 0.017
Rich DANN ResNet50 129 bottleneck 256	0.844 ± 0.008

DANN SPL

Основная идея: использовать эмбединги из DANN, а не из ResNet для обучения SPL




Модель-источник	Ассурасу для модели-источника A->W	Ассурасу для SPL с использованием данного источника A->W
ResNet50 (статья)	0.664	0.927
ResNet50	0.664	0.927
ResNet50 fine-tuned	0.73	0.863
DANN Rich	0.8649	0.906
DANN Rich Entropy	0.8997	0.903

Wang, Qian, u Toby P. Breckon. «Unsupervised Domain Adaptation via Structured Prediction Based Selective Pseudo-Labeling.» arxiv. 2019. <https://arxiv.org/abs/1911.07982>.

Визуализация результатов

tsne ResNet 50, fine-tuned



DANN Rich entropy

